

ΕΡΓΑΣΙΑ ΕΞΑΜΗΝΟΥ

Πολυτροπική Ανάλυση Μουσικών Δεδομένων

Multimodal Music Analysis

Μάθημα: Τεχνικές Εξόρυξης Δεδομένων

Γλώσσα Υλοποίησης: Python (pandas, scikit-learn, numpy, matplotlib/seaborn, gensim/transformers)

Παραδοτέα: Ένα (1) Jupyter Notebook (.ipynb) ανά μέρος, πλήρως τεκμηριωμένο.



ΟΜΑΔΙΚΗ ΕΡΓΑΣΙΑ (έως 2 άτομα)

Ατομικές υποβολές δεν θα γίνουν δεκτές.

Περιγραφή

Στόχος της εργασίας είναι η ανάπτυξη ενός ολοκληρωμένου pipeline εξόρυξης γνώσης από μουσικά δεδομένα, συνδυάζοντας δύο διαφορετικές πηγές πληροφορίας (modalities): **Ήχο** (Audio) και **Κείμενο** (Στίχοι/Lyrics). Θα κληθείτε να εφαρμόσετε τεχνικές

- προεπεξεργασίας
- εξαγωγής χαρακτηριστικών μέσω Embeddings
- οπτικοποίησης δεδομένων
- κατηγοριοποίησης
- αξιολόγησης μοντέλων

Το dataset περιλαμβάνει:

1. **Audio features/Metadata:** (π.χ. έτοιμα low-level features).
2. **Lyrics:** Το κείμενο των στίχων.
3. **Labels:** Η κατηγορία (Genre) ή/και το συναίσθημα (Sentiment/Valence).
4. **Tags:** Τα tags (User Generated Content) δίνουν την "ανθρώπινη" ερμηνεία του τραγουδιού



ΜΕΡΟΣ Α: Προεπεξεργασία, Embeddings και Εξερευνητική Ανάλυση

Παράδοση: 19/04/2026

Στόχος: Η μετατροπή των δεδομένων σε κατάλληλες διανυσματικές αναπαραστάσεις (Embeddings) και η μελέτη τους μέσω οπτικοποιήσεων.

1. Συλλογή Δεδομένων (Data collection)

Σας δίνονται 5 αρχεία στο eclass. Το πρώτο βήμα είναι να τα “συνδέσετε”. Χρησιμοποιήστε την βιβλιοθήκη pandas για να φορτώσετε τα αρχεία και εξετάστε τη δομή τους. Το πεδίο-κλειδί για τη σύνδεση είναι το id (**Song ID**).

- **Filtering:** Επιλέξτε μόνο τα τραγούδια που ανήκουν στα 5 πιο συχνά μουσικά είδη (Top-5 Genres) όπως προκύπτουν από το id_genres.csv. Αγνοήστε όλα τα υπόλοιπα. (Σημ. Μπορείτε όμως και να χρησιμοποιήσετε genres της δικής σας επιλογής).
- **Intersection:** Κρατήστε μόνο τα τραγούδια για τα οποία έχετε δεδομένα και στα 3 αρχεία (Audio Stats, Lyrics, Genre).
- **Αποτέλεσμα:** Ένα καθαρό pandas DataFrame (ή CSV) που περιέχει μόνο τα τελικά τραγούδια (π.χ. 5.000 - 10.000 εγγραφές) με στήλες: id, genre, lyrics, mfcc_stats.

***Tip: Διαχείριση Μεγάλων Αρχείων:** Η τεχνική που ψάχνετε είναι η χρήση του **chunksize** στην `pd.read_csv`. Αυτό επιτρέπει να διαβάσετε ένα αρχείο τμηματικά (π.χ. ανά 500 γραμμές), να φιλτράρετε/επεξεργάζεστε κάθε κομμάτι, και να κρατάτε στη μνήμη μόνο ότι επιθυμείτε κάθε φορά. Επίσης, μπορείτε να διαβάσετε συμπιεσμένα αρχεία `.tar.gz` ή `.zip` απευθείας μέσω Python, να κάνετε `iterate` τα περιεχόμενα, και να εξάγετε το `text` μόνο αν το όνομα του αρχείου ταιριάζει με κάποιο ID από τη λίστα στόχο.*

2. Εξαγωγή Χαρακτηριστικών & Embeddings (Feature Extraction)

Απαιτείται η δημιουργία δύο ξεχωριστών πινάκων χαρακτηριστικών:

- **Text Embeddings:**
 - **Word Embeddings:** Εκπαιδεύστε ένα μοντέλο **Word2Vec** ή **Doc2Vec** (χρησιμοποιώντας τη βιβλιοθήκη `gensim`) πάνω στο corpus των στίχων σας.
 - **Εναλλακτικά/Bonus:** Χρησιμοποιήστε προ-εκπαιδευμένα embeddings (π.χ. GloVe ή BERT-based sentence transformers) για να εξάγετε ένα πυκνό διάνυσμα (dense vector) για κάθε τραγούδι (π.χ. μέσος όρος των word vectors ή CLS

token).

- **Audio Embeddings:**

- Για τον ήχο, σας δίνονται υψηλής διάστασης στατιστικά χαρακτηριστικά MFCC (Mean & Covariance matrix flattened). Αυτά τα διανύσματα είναι πολύ μεγάλα και θορυβώδη. Ζητούμενο: Δημιουργήστε συμπαγή **Audio Embeddings** εφαρμόζοντας τεχνικές Learning/Reduction:
 - **PCA:** Κρατήστε το 95% της διακύμανσης.
 - (Bonus) **Autoencoder:** Εκπαιδεύστε ένα απλό νευρωνικό δίκτυο (Dense Autoencoder με Keras/sklearn) που να συμπιέζει τα MFCC stats σε ένα bottleneck layer (π.χ. 32 διαστάσεις). Αυτό το compressed vector θα είναι το 'Audio Embedding' σας

3. Οπτικοποίηση και Ανάλυση (Exploratory Data Analysis - EDA)

- **Word Clouds ανά Genre:** Επιλέξτε τα 2 πιο διαφορετικά μεταξύ τους είδη (π.χ. Metal και Pop). Για το καθένα, συγκεντρώστε όλα τα tags των τραγουδιών του και δημιουργήστε ένα Word Cloud.
- **Bar Chart:** Ποια είναι τα 10 πιο συχνά tags σε ολόκληρο το dataset;
- **Dimensionality Reduction:** Εφαρμόστε **PCA** ή **t-SNE** στα Text Embeddings και στα Audio Embeddings ξεχωριστά για να μειώσετε τις διαστάσεις σε 2D.
 - **Plots:**
 - Δημιουργήστε 2D Scatter plots των τραγουδιών, χρωματισμένα με βάση την κατηγορία (Genre). Παρατηρήστε αν σχηματίζονται συστάδες (clusters).
 - Συγκρίνετε οπτικά: Ποια modality (Audio ή Text) φαίνεται να διαχωρίζει καλύτερα τις κλάσεις;
- **Similarity Analysis:** Υλοποιήστε κώδικα που, δοθέντος ενός τραγουδιού, βρίσκει τα 5 πιο "όμοια" τραγούδια βάσει συνημιτονικής ομοιότητας (Cosine Similarity), πρώτα με βάση τους στίχους και μετά με βάση τον ήχο. Σχολιάστε τις διαφορές στα αποτελέσματα.



ΜΕΡΟΣ Β: Κατηγοριοποίηση, Fusion και Αξιολόγηση

Παράδοση: 31/05/2026

Στόχος: Η ανάπτυξη μοντέλων μηχανικής μάθησης για την πρόβλεψη της κατηγορίας/συναισθήματος και η συγκριτική αξιολόγηση της συνεισφοράς του ήχου και του κειμένου.

1. Classification Models (Unimodal)

Εκπαιδεύστε 2 ταξινομητές της επιλογής σας (π.χ. SVM, Random Forest, k-NN κτλ) για το πρόβλημα του **Genre Classification**:

- **Model A (Text-only)**: Χρησιμοποιεί ως είσοδο μόνο τα Text Embeddings.
- **Model B (Audio-only)**: Χρησιμοποιεί ως είσοδο μόνο τα Audio Embeddings.

2. Multimodal Fusion (Συνδυασμός)

Υλοποιήστε και τις δύο παρακάτω στρατηγικές (δεν θα βρείτε έτοιμη συνάρτηση "fusion" στο sklearn, πρέπει να διαχειριστείτε τους πίνακες `numpy`):

- **Early Fusion**: Συνένωση (Concatenation) των διανυσμάτων Audio και Text σε ένα ενιαίο διάνυσμα **πριν** την εκπαίδευση του μοντέλου. Εκπαιδεύστε ένα **Model C (Fused)**.
- **Late Fusion**: Χρησιμοποιήστε τις πιθανότητες εξόδου (prediction probabilities) των Model A και Model B. Συνδυάστε τις (π.χ. μέσος όρος πιθανοτήτων ή soft voting) για να βγάλετε την τελική απόφαση.

3. Πειραματική Διαδικασία & Αξιολόγηση (Evaluation)

- **Cross-Validation**: Χρησιμοποιήστε 10-fold Cross-Validation για όλα τα πειράματα.
- **Metrics**: Καταγράψτε Accuracy, Precision, Recall, F1-score (Macro-averaged).
- **Confusion Matrices**: Δημιουργήστε τους πίνακες για τα Model A, B και C.
- **Σύγκριση**:
 - Δημιουργήστε ένα συγκεντρωτικό γράφημα (Bar chart) που συγκρίνει το F1-score των τριών προσεγγίσεων (Audio vs Text vs Combined).
 - Απαντήστε τεκμηριωμένα: Βοήθησε ο συνδυασμός των δεδομένων; Υπάρχουν κατηγορίες που προβλέπονται καλύτερα από το κείμενο και άλλες από τον ήχο;

4. Clustering (Unsupervised Learning)

Εφαρμόστε τον αλγόριθμο **K-Means** στο συνδυαστικό (Fused) διάνυσμα. Χρησιμοποιήστε μετρικές όπως το **Silhouette Score** για να βρείτε τον βέλτιστο αριθμό clusters. Συγκρίνετε τα clusters που προέκυψαν με τα πραγματικά labels χρησιμοποιώντας το Adjusted Rand Index (ARI).

Οδηγίες για το παραδοτέο

Η εργασία είναι ομαδική και μπορεί να εκπονηθεί σε ομάδες **έως 2 ατόμων**.

- Θα ανεβάσετε στο **eclass** ένα φάκελο της μορφής sdixxxx.zip (όπου sdi το ΑΜ ενός εκ των ατόμων της ομάδας) ο οποίος θα περιέχει μόνο τον κώδικά σας σε μορφή **ipython notebook** (προσοχή: δεν χρειάζεται να ανεβάσετε και τα αρχεία που θα επεξεργαστείτε). Το ίδιο μέλος που έκανε την υποβολή στο Α μέρος της εργασίας θα κάνει και την υποβολή στο Β μέρος της εργασίας.
 - Το notebook πρέπει στην αρχή να περιέχει **τα ονόματα και τους ΑΜ** των μελών της ομάδας (το πλήρες όνομα σας στα ελληνικά!).
 - Το notebook πρέπει να έχει **“τρέξει”** ώστε να φαίνονται τα αποτελέσματα της εργασίας σας και όλες οι οπτικοποιήσεις. Το notebook αποτελεί και την ολοκληρωμένη αναφορά για την εργασία σας (δεν θα παραδώσετε τίποτα σε doc, pdf) , σχεδιάστε το με προσοχή, να θυμάστε να γράψετε ποιο ερώτημα απαντάται σε κάθε κελί.
 - Διευκρινίσεις για την εργασία θα δίνονται μέσω του e-class.
 - Εργασίες που δεν έχουν “τρέξει” δεν μπορούν να βαθμολογηθούν.
 - Εργασίες **δεν γίνονται δεκτές με email**, φροντίστε να είστε συνεπείς στην υποβολή της εργασίας σας.
-

Κριτήρια Αξιολόγησης Εργασίας

1. **Ορθότητα (40%)**: Σωστή χρήση βιβλιοθηκών, απουσία bugs, σωστή υλοποίηση του fusion και του cross-validation.
 2. **Ανάλυση & Σχολιασμός (30%)**: Η ποιότητα των Markdown cells στο Notebook. Δεν αρκεί να τρέχει ο κώδικας· πρέπει να εξηγείτε *τι* βλέπουμε στα διαγράμματα και *γιατί* συμβαίνει (π.χ. "Τα embeddings του κειμένου διαχωρίζουν καλύτερα το Rap από την Pop γιατί...").
 3. **Ποιότητα Γραφημάτων (20%)**: Ευανάγνωστα διαγράμματα, με σωστούς άξονες, τίτλους και legends.
 4. **Δυσκολία/Πρωτοτυπία (10%)**: Bonus για χρήση advanced embeddings (BERT/Transformers) ή advanced fusion techniques.
-

Χρήσιμοι σύνδεσμοι

<https://anasdrak.sites.aueb.gr/index.php/python-ai-scikit-learn/>

<https://huggingface.co/sentence-transformers/stsb-bert-base>


<https://huggingface.co/learn>

<https://www.kaggle.com/learn/pandas>

https://pandas.pydata.org/docs/user_guide/10min.html

Τα δεδομένα για την εργασία είναι από το παρακάτω σύνδεσμο

<https://zenodo.org/records/15394646>



ΚΑΛΗ ΕΠΙΤΥΧΙΑ!

